ANALISIS UNGGAHAN MEDIA SOSIAL TENTANG KECEMASAN MENGGUNAKAN TOPIC MODELING

Disusun Oleh :

Kelompok 7

Verdina Tista P	K1D024002
Ardika Wahyu Fariz	K1D024013
Muflihah Qurrota	K1D024024
Arroja Aliya Fadhilah	K1D024037
Andhika Pradana R.D.	K1D024038

Disusun untuk memenuhi tugas terstruktur :

Mata Kuliah : Pengantar Sains Data

Dosen : Lutfia Maharani Siniwi S.Stat., M. Stat.

KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI

UNIVERSITAS JENDERAL SOEDIRMAN

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM

PROGRAM STUDI STATISTIKA

PURWOKERTO

2025

DAFTAR ISI

DAFTAR ISI ..... **i**
DAFTAR TABEL ..... **iv**
DAFTAR GAMBAR ..... **iii**
BAB I PENDAHULUAN **1**
1.1 Latar Belakang 1
1.2 Tujuan dan Ruang Lingkup Proyek 1
1.3 Metode yang Digunakan Secara Umum 2
BAB II TINJAUAN PUSTAKA **3**
2.1 Analisis Sentimen, Topic Modeling, dan Clustering 3
2.1.1 Analisis Sentimen 3
2.1.2 Topic Modeling 3
2.1.3 Clustering dalam Analisis Teks 3
2.2 Normalisasi Teks Media Sosial 4
2.3 Evaluasi Model Topic Modeling 4
2.4 Penelitian Terkait 4
2.5 Kerangka Teori yang Mendukung 5
BAB III METODE PENELITIAN **6**
3.1 Metode yang Digunakan 6
3.2 Langkah-langkah Implementasi 6
3.3 Deskripsi Dataset yang Digunakan 8
3.4 Proses yang Dilakukan 8
3.5 *PseudoCode* yang Digunakan 9
BAB IV HASIL DAN ANALISIS **11**
4.1 Hasil Model LDA beserta Skor Koherensi 11
4.2 Topik yang Terbentuk 12
4.3 Perbandingan Hasil dengan Penelitian Sejenis 13
BAB V PENTUTUP **15**
5.1 Ringkasan Temuan Utama Proyek. 15
5.2 Saran 16
DAFTAR PUSTAKA **17**

LAMPIRAN.....18
Lampiran 1. Tautan Kode Program (Google Colab).....18
Lampiran 2. Tautan Data yang Digunakan 18
Lampiran 3. Gambar Wordcloud 18
Lampiran 4. Kata terbanyak tiap topik.....19

DAFTAR GAMBAR

Gambar 1. Wordcloud Data Keseluruhan 18
Gambar 2. Kata Terbanyak pada Topik 1 19
Gambar 3. Kata Terbanyak Topik 2 19
Gambar 4. Kata Terbanyak Topik 3 20
Gambar 5. Kata Terbanyak Topik 4 20
Gambar 6. Kata Terbanyak Topik 5 21

DAFTAR TABEL

Tabel 1. Skor Koherensi untuk masing-masing Jumlah Topik.....11

BAB I
PENDAHULUAN

1.1 Latar Belakang

Media sosial seperti Twitter/X, Instagram, dan TikTok menjadi ruang bagi masyarakat untuk mengekspresikan opini, pengalaman, dan emosi secara terbuka. Banyaknya postingan yang muncul setiap hari membuat media sosial menyimpan data teks yang sangat besar dan beragam, sehingga berpotensi digunakan untuk memahami isu yang sedang ramai dibicarakan. Namun, data teks di media sosial bersifat tidak terstruktur, penuh variasi bahasa, singkatan, dan noise, sehingga sulit dianalisis secara manual.

Untuk mengatasi hal tersebut, dibutuhkan teknik analisis otomatis yang mampu menemukan pola pembahasan utama dari kumpulan teks. Salah satu pendekatan yang umum digunakan adalah topic modeling, yaitu metode unsupervised learning yang dapat mengelompokkan dokumen berdasarkan kemiripan kata dan mengekstraksi topik-topik utama yang tersembunyi di dalam data. Dengan topic modeling, peneliti dapat melihat tema dominan, persebaran topik, serta makna dari percakapan publik secara lebih efisien.

Pada proyek ini, topic modeling diterapkan pada 500 postingan media sosial berbahasa Indonesia yang berkaitan dengan kegelisahan atau kecemasan, ditandai dengan kemunculan kata seperti “gelisah”, “cemas”, “resah”, atau “overthinking”. Analisis ini penting karena isu kesehatan mental semakin sering dibicarakan di media sosial, dan pemetaan topik dapat membantu memahami aspek-aspek yang paling banyak dikeluhkan atau dirasakan masyarakat. Hasil dari penelitian ini diharapkan memberikan gambaran tematik yang jelas sekaligus insight terkait percakapan kesehatan mental di media sosial.

1.2 Tujuan dan Ruang Lingkup Proyek

Proyek ini bertujuan untuk menerapkan teknik topic modeling pada data teks media sosial berbahasa Indonesia agar dapat menemukan pola pembahasan yang muncul secara otomatis. Secara khusus, tujuan utama proyek adalah menghasilkan sekitar 5–10 topik inti beserta kata-kata penyusunnya yang paling representatif, sehingga kumpulan postingan yang besar dapat diringkas menjadi beberapa tema penting. Selain itu, proyek ini juga bertujuan menganalisis distribusi topik pada setiap dokumen atau postingan, sehingga dapat diketahui topik mana yang paling dominan dan bagaimana variasi topik pada data. Hasil topik yang terbentuk kemudian diinterpretasikan secara kualitatif untuk memberikan pemahaman terhadap makna setiap topik sekaligus menyusun insight terkait percakapan pengguna media sosial.

Ruang lingkup proyek dibatasi pada analisis teks pendek yang berasal dari media sosial dengan jumlah data minimal 500 postingan. Dataset yang digunakan pada proyek ini diperoleh dari Kaggle, sehingga proses pengumpulan data langsung dari API atau scraping tidak menjadi fokus utama. Topik studi kasus yang diangkat berhubungan dengan kesehatan mental, khususnya kegelisahan dan kecemasan, yang tercermin dari kemunculan kosakata emosional dalam postingan. Output yang dihasilkan mencakup daftar topik yang

muncul, visualisasi persebaran topik pada setiap dokumen, wordcloud untuk menggambarkan kata dominan pada setiap topik, serta evaluasi kualitas topik menggunakan coherence score. Dengan batasan ini, proyek diharapkan menghasilkan analisis yang terarah dan dapat dipertanggungjawabkan.

1.3 Metode yang Digunakan Secara Umum.

Tahapan proyek dimulai dengan mengambil dataset media sosial dari Kaggle yang sesuai dengan studi kasus. Dari dataset tersebut, dilakukan proses seleksi untuk mengambil 500 postingan sebagai data yang dianalisis. Setelah itu, dilakukan pemeriksaan awal untuk memahami karakteristik teks, termasuk bentuk bahasa yang tidak baku dan banyaknya istilah slang yang muncul. Karena konteks media sosial sering memakai singkatan maupun kata gaul, tim menyusun kamus normalisasi dan daftar slang sendiri agar kata-kata tersebut dapat diubah ke bentuk baku sebelum dianalisis.

Tahap berikutnya adalah preprocessing, meliputi case folding, pembersihan simbol/URL/emoji yang tidak relevan, tokenisasi, penghapusan stopwords, serta stemming atau lemmatization. Setelah teks bersih dan sudah dinormalisasi menggunakan kamus slang yang dibuat, data diubah menjadi representasi numerik seperti Bag-of-Words atau TF-IDF. Selanjutnya, topic modeling diterapkan untuk mengekstraksi topik-topik utama tanpa label. Hasil topik dievaluasi menggunakan coherence score untuk menilai keterpaduan kata dalam topik, lalu divisualisasikan melalui distribusi topik dan *wordcloud*. Seluruh hasil tersebut kemudian diinterpretasikan dan disusun menjadi laporan sebagai insight dari percakapan media sosial.

BAB II
TINJAUAN PUSTAKA

2.1 Analisis Sentimen, Topic Modeling, dan Clustering

2.1.1 Analisis Sentimen

Analisis sentimen merupakan metode dalam *text mining* yang bertujuan mengidentifikasi opini, emosi, atau sikap pengguna terhadap suatu objek berdasarkan teks yang dihasilkan. Pada konteks media sosial, analisis sentimen membantu memahami bagaimana masyarakat mengekspresikan perasaan seperti cemas, gelisah, atau stres melalui unggahan mereka. Meskipun proyek ini menitikberatkan pada topic modeling, konsep analisis sentimen tetap relevan sebagai landasan teori dalam kajian teks emosional.

2.1.2 Topic Modeling

Topic modeling adalah metode *unsupervised learning* untuk menemukan struktur tersembunyi atau topik laten dalam sekumpulan dokumen teks tanpa memerlukan label kategori. Beberapa model topic modeling yang umum digunakan yaitu:

1. Latent Dirichlet Allocation (LDA)
   LDA merupakan metode topic modeling paling populer. LDA bekerja dengan asumsi bahwa setiap dokumen terdiri dari campuran beberapa topik, dan setiap topik terdiri dari kumpulan kata dengan probabilitas tertentu. Kelebihan LDA adalah kemampuannya menghasilkan topik yang interpretatif dan stabil, sehingga cocok digunakan untuk data teks media sosial.
2. Latent Semantic Analysis (LSA)
   LSA menggunakan dekomposisi matriks (Singular Value Decomposition) untuk mereduksi dimensi data teks dan mengekstraksi hubungan semantik antar kata. Namun, LSA kurang mampu menangani data dengan konteks yang kompleks dibandingkan dengan LDS.
3. Non-Negative Matrix Factorization (NMF)
   NMF merupakan alternatif lain yang mendekomposisi matriks kata-dokumen menjadi dua matriks non-negatif. Metode ini sering digunakan untuk data yang bersifat *sparse* dan dapat menghasilkan topik yang mudah diinterpretasi.

2.1.3 Clustering dalam Analisis Teks

Clustering atau pengelompokan adalah teknik *unsupervised learning* yang bertujuan mengelompokkan data berdasarkan kesamaan karakteristik. Dalam analisis teks, metode seperti *K-Means* atau *Hierarchical Clustering* dapat digunakan untuk mengelompokkan dokumen berdasarkan kesamaan kata atau vektor representasi teks. Meskipun *clustering* dapat digunakan untuk mengelompokkan dokumen, *topic modeling* dianggap lebih tepat untuk mengekstraksi topik laten karena mampu menangani konsep “satu dokumen dengan banyak topik”.

2.2 Normalisasi Teks Media Sosial

Data teks dari media sosial sering kali mengandung *noise* seperti singkatan, kata gaul (*slang*), typo, dan emoticon. Oleh karena itu, normalisasi teks menjadi langkah penting sebelum pemrosesan lebih lanjut. Normalisasi teks media sosial meliputi:

1. Konversi slang ke bentuk baku: Menggunakan kamus *slang* yang disusun berdasarkan observasi data atau referensi eksternal.
2. Koreksi kesalahan pengetikan (*spelling correction*): Dapat dilakukan dengan algoritma *Levenshtein distance* atau menggunakan pustaka seperti *TextBlob*.
3. Penghapusan karakter tidak relevan: Seperti URL, tagar (*hashtag*), dan mention (*@username*).

2.3 Evaluasi Model Topic Modeling

Evaluasi kualitas topik yang dihasilkan oleh model dapat dilakukan secara kuantitatif dan kualitatif. Metode kuantitatif yang umum digunakan adalah:

1. Coherence Score
   Coherence score mengukur sejauh mana kata-kata dalam suatu topik saling berkaitan secara semantik. Nilai koherensi yang tinggi menunjukkan topik yang mudah diinterpretasi. Metode *c_v* dan *u_mass* sering digunakan dalam penelitian.
2. Perplexity
   Perplexity mengukur seberapa baik model memprediksi data uji. Nilai *perplexity* yang rendah menunjukkan model yang lebih baik. Namun, *perplexity* tidak selalu berkorelasi dengan kualitas interpretasi topik.
3. Evaluasi Kualitatif
   Evaluasi kualitatif dilakukan dengan mengamati kata-kata penyusun topik dan memberi label yang sesuai berdasarkan interpretasi peneliti. Hal ini penting untuk memastikan topik yang dihasilkan relevan dengan konteks penelitian.

2.4 Penelitian Terkait

Penelitian terkait dalam bidang analisis teks dan pemodelan topik berbasis *Natural Language Processing* (NLP) telah mengalami perkembangan signifikan, khususnya dengan pemanfaatan model bagasa berbasis *transformer*. Salah satu penelitian yang relevan dilakukan oleh Setiawan et al. (2025) yang mengkaji klasterisasi topik aduan mahasiswa menggunakan pendekatan *semantic clustering* berbasis IndoBERT dan algoritma K-Means.

Penelitian tersebut bertujuan untuk mengelompokkan aduan mahasiswa berdasarkan kesamaan makna semantik, bukan sekedar kemunculan kata. Proses penelitian diawali dengan tahap *preprocessing* teks yang meliputi pembersihan data, normalisasi, dan tokenisasi. Selanjutnya, teks aduan diubah menjadi representasi vektor menggunakan *embedding* IndoBERT yang telah dilatih khusus untuk Bahasa Indonesia. Representasi semantik ini kemudian dikelompokkan menggunakan algoritma K-Means.

Hasil penelitian menunjukkan bahwa jumlah klaster optimal adalah emapt klaster yang ditentukan melalui evaluasi Silhouette Score dan Elbow Method. Visualisasi klaster menggunakan t-SNE memperlihatkan pemisahan klaster yang cukup jelas, meskipun terdapat satu klaster yang menunjukkan indikasi tumpang tindih topik. Evaluasi kualitas topik dilakukan menggunakan metrik Topic Coherence (c_v), di mana salah satu klaster

memperoleh skor koherensi tertinggi sebesar 0,7084, yang menunjukkan keterkaitan semantik yang kuat antar kata dalam klaster tersebut.

Topik-topik utama yang dihasilkan dalam penelitian tersebut meliputi fasilitas, layanan, proses perkuliahan, serta kesan dan harapan mahasiswa terhadap institusi. Temuan ini membuktikan bahwa pendekatan *semantic embedding* menggunakan IndoBERT mampu menghasilkan klaster topik yang lebih representatif dibandingkan metode tradisional seperti LDA yang kurang mampu menangkap konteks kata secara mendalam.

Penelitian ini memiliki keterkaitan metodologis yang kuat dengan penelitian yang akan dilakukan, terutama dalam penggunaan pendekatan *unsupervised learning* berbasis representasi semantik. Perbedaannya terletak pada objek kajian, di mana penelitian ini berfokus pada ungkapan kegelisahan (anxiety) di media sosial Indonesia, sehingga diperlukan penyesuaian konteks, normalisasi bahasa informal, serta interpretasi topik berdasarkan perspektif psikologis.

2.5 Kerangka Teori yang Mendukung

Penelitian ini didukung oleh beberapa kerangka teori utama yang saling terintegrasi yaitu teori psikologi, pemrosesan Bahasa alami, dan *data mining*:

1. Teori Psikologi Kesehatan Mental

   Konsep kegelisahan dan kecemasan dipahami sebagai respons emosional individu terhadap tekanan atau ketidakpastian yang dapat muncul dalam berbagai bentuk ekspresi bahasa. Teori kecemasan digunakan sebagai landasan untuk menginterpretasikan topik-topik yang dihasilkan dari klaster teks, khususnya dalam mengidentifikasi pola keluhan, kekhawatiran, dan harapan yang diekspresikan pengguna media sosial.

2. *Natural Language Processing (NLP)*

   Pendekatan NLP menjadi fondasi utama dalam pengolahan data teks tidak terstruktur. Mengacu pada penelitian Setiawan et al. (2025), penggunaan IndoBERT memungkinkan pemahaman makna teks secara kontekstual dan *bidirectional*, sehingga mampu menangkap nuansa bahasa Indonesia yang kompleks, termasuk variasi makna kata dalam konteks yang berbeda.

3. Data Mining dan Unsupervised Learning

   Pendekatan *data mining* digunakan untuk mengekstraksi pola tersembunyi dari data teks dalam jumlah besar. Algoritma K-Means clustering berperan dalam mengelompokkan data berdasarkan kemiripan vektor hasil embedding IndoBERT. Evaluasi klaster dilakukan menggunakan metrik kuantitatif seperti Silhouette Score, Topic Coherence, dan visualisasi t-SNE, sebagaimana diterapkan dalam penelitian Setiawan et al. (2025), guna memastikan kualitas dan keterpisahan topik.

Dengan mengintegrasikan ketiga kerangka teori tersebut, penelitian ini diharapkan mampu menghasilkan analisis topik kegelisahan di media sosial yang tidak hanya kuat secara teknis, tetapi juga relevan secara psikologis dan kontekstual dalam lingkungan sosial Indonesia.

.

BAB III
METODE PENELITIAN

3.1 Metode yang Digunakan

Penelitian ini menggunakan metode Topic Modeling, yaitu teknik *unsupervised learning* untuk menemukan topik-topik laten (tema tersembunyi) dari kumpulan dokumen teks. Topic modeling bekerja dengan mengelompokkan kata-kata yang sering muncul bersama sehingga membentuk suatu topik yang merepresentasikan pembahasan tertentu pada data.

Model yang digunakan adalah Latent Dirichlet Allocation (LDA). LDA mengasumsikan bahwa:

1. Setiap dokumen (tweet) tersusun dari campuran beberapa topik.
2. Setiap topik tersusun dari distribusi probabilitas kata-kata.

Dengan demikian, LDA dapat mengekstraksi topik dominan dalam tweet serta kata-kata yang menjadi ciri utama tiap topik. Hasil topic modeling pada penelitian ini selanjutnya dianalisis untuk memahami isu atau tren utama yang muncul pada percakapan Twitter.

3.2 Langkah-langkah Implementasi

Implementasi topic modeling pada penelitian ini dilakukan melalui beberapa tahap sistematis sebagai berikut:

1. Studi awal dan penentuan fokus topik
   Peneliti menentukan konteks/isu yang ingin dianalisis pada Twitter, lalu memastikan dataset Kaggle yang dipilih relevan dengan fokus tersebut. Tahap ini juga mencakup peninjauan singkat literatur untuk memastikan metode LDA sesuai dengan tujuan penelitian.
2. Pengambilan dataset dari Kaggle
   Dataset Twitter diunduh dari Kaggle dalam format CSV. Dataset ini berisi postingan Twitter mentah dengan variasi bahasa, gaya penulisan, dan noise khas media sosial.
3. Random sampling 500 tweet
   Karena dataset Kaggle jumlahnya besar, dilakukan pengambilan sampel acak sebanyak 500 tweet. Random sampling dipilih agar sampel tetap mewakili populasi dataset, mengurangi bias seleksi manual, dan menyesuaikan keterbatasan waktu/komputasi penelitian.
4. Pemeriksaan kualitas data awal (data screening)
   Sampel 500 tweet diperiksa untuk memastikan:
   - tidak ada baris kosong,
   - tidak ada duplikasi ekstrem,
   - format teks terbaca dengan benar (encoding normal). Jika ada data yang rusak/duplikat maka dihapus.

5. Pembuatan kamus bantu
   Untuk menyesuaikan karakter bahasa Twitter, peneliti membuat:
   - Kamus stopword tambahan: berisi kata-kata yang terlalu umum atau tidak relevan dengan topik sehingga perlu dihapus (misal kata seru, bentuk sapaan tertentu, kata penghubung informal).
   - Kamus slang/normalisasi sendiri: berisi pasangan kata gaul → kata baku sesuai temuan di data (mis. "gpp" → "tidak apa-apa", "bgt" → "banget", dll).
     Kamus ini disusun dari hasil observasi data dan referensi slang Bahasa Indonesia.
6. Preprocessing teks
   Sampel tweet dibersihkan dan dinormalisasi melalui beberapa sub-tahap (lihat detail pada 3.4.2). Tujuan preprocessing adalah mengurangi noise dan menghasilkan token bersih agar LDA dapat membentuk topik yang koheren.
7. Pembentukan dictionary (Gensim Dictionary)
   Setelah preprocessing, seluruh token dari setiap tweet dikumpulkan untuk membentuk dictionary yang memetakan setiap kata unik menjadi ID numerik. Dictionary ini menjadi dasar perhitungan probabilitas LDA.
8. Pembentukan corpus Bag-of-Words (BoW)
   Setiap tweet diubah menjadi representasi BoW, yaitu daftar pasangan (id_kata, frekuensi). Corpus BoW adalah input utama bagi pelatihan LDA.
9. Pelatihan model LDA multi-skema topik
   LDA dilatih berulang dengan jumlah topik yang berbeda (mis. 5–10 topik). Pelatihan multi-skema bertujuan mendapatkan konfigurasi topik yang paling stabil dan mudah diinterpretasikan.
10. Evaluasi coherence score untuk memilih topik terbaik
    Untuk setiap jumlah topik diuji, dihitung coherence score (c_v). Model dengan coherence paling tinggi dipilih sebagai model final karena menandakan kata-kata dalam topik saling berkaitan secara semantik.
11. Pelatihan ulang model final
    Setelah jumlah topik optimal ditemukan, model LDA dilatih ulang menggunakan nilai topik tersebut agar hasil topik final lebih konsisten.
12. Ekstraksi dan interpretasi topik
    Peneliti menampilkan 5–10 kata teratas dari tiap topik, lalu memberi label/tema makna topik berdasarkan keterkaitan kata dan contoh tweet teratas.
13. Analisis topik dominan per dokumen
    Setiap tweet dihitung probabilitas topiknya, lalu ditentukan topik dominan. Hasil ini digunakan untuk melihat tema apa yang paling banyak dibicarakan.
14. Visualisasi hasil
    Untuk memperjelas temuan, dilakukan:
    - Visualisasi distribusi topik (proporsi tweet per topik)
    - Visualisasi *wordcloud* tiap topi

3.3 Deskripsi Dataset yang Digunakan

Dataset yang digunakan dalam penelitian ini berasal dari Kaggle, yaitu kumpulan data berisi postingan Twitter dalam format CSV. Dataset Twitter dipilih karena memiliki jumlah data yang besar, beragam, dan sesuai untuk analisis berbasis teks seperti topic modeling. Tweet pada dataset ini memuat percakapan spontan pengguna media sosial sehingga cocok untuk mengidentifikasi topik-topik laten yang muncul secara alami dari interaksi publik.

Dataset Kaggle tersebut berisi ribuan postingan Twitter dengan berbagai tema. Untuk menyesuaikan ruang lingkup penelitian serta mempertimbangkan keterbatasan waktu dan komputasi, dilakukan pengambilan sampel acak (random sampling) terhadap dataset tersebut. Melalui proses ini, dipilih 500 tweet secara acak untuk dianalisis lebih lanjut. Random sampling digunakan agar sampel tetap representatif terhadap keseluruhan dataset dan mengurangi potensi bias seleksi.

Dataset ini bersifat unlabeled, artinya tidak memiliki penanda kategori atau kelas tertentu sehingga sangat tepat digunakan untuk metode *unsupervised learning* seperti topic modeling. Selain itu, karakteristik teks dalam dataset cukup beragam, mengandung bahasa informal, singkatan, kata gaul (slang), emoji, dan komponen khas Twitter lainnya. Hal ini membuat tahap preprocessing menjadi penting untuk menghasilkan representasi teks yang lebih bersih dan siap diproses oleh model.

Dengan demikian, dataset Kaggle hasil sampling ini menyediakan fondasi yang memadai untuk membangun model topic modeling dan mengeksplorasi tema-tema yang berkembang di dalam percakapan publik pada media sosial Twitter.

3.4 Proses yang Dilakukan

Proses penelitian ini dilakukan secara bertahap dan sistematis untuk memastikan bahwa data teks yang dianalisis telah siap digunakan dalam pemodelan topik serta menghasilkan topik yang koheren dan mudah diinterpretasikan. Secara umum, proses yang dilakukan dapat dibagi menjadi beberapa tahapan utama, yaitu preprocessing data teks, pembentukan representasi data, pemodelan topik, dan evaluasi hasil.

Tahap pertama adalah preprocessing data teks, yang bertujuan untuk membersihkan dan menormalkan tweet agar dapat dianalisis secara efektif. Proses preprocessing meliputi:

1. Case folding, yaitu mengubah seluruh teks menjadi huruf kecil agar tidak terjadi perbedaan makna akibat perbedaan kapitalisasi huruf.
2. Cleaning, dengan menghapus URL, mention (@username), hashtag, angka, tanda baca, dan karakter non-alfabet yang tidak relevan terhadap analisis topik.
3. Tokenisasi, yaitu memecah teks menjadi unit kata (token) agar dapat diproses lebih lanjut.
4. Normalisasi kata, dengan mengganti kata gaul atau singkatan menggunakan kamus slang yang telah disusun sebelumnya sehingga kata-kata informal diubah ke bentuk baku.
5. Stopword removal, yaitu menghapus kata-kata yang sangat umum dan kurang membawa makna topik. Contoh stopword yang biasanya dihapus misalnya: “dan”, “di”, “ke”, “dari”, “ini”, “itu”, “atau”, “pada”, “untuk”.

6. Stemming, yaitu mengubah kata berimbuhan menjadi kata dasar agar variasi kata yang memiliki makna sama dapat disatukan.

Tahap kedua adalah pembentukan representasi data, di mana hasil preprocessing diubah menjadi bentuk numerik agar dapat diproses oleh model. Pada tahap ini dilakukan pembuatan *dictionary* menggunakan Gensim, yang memetakan setiap kata unik ke dalam ID numerik. Selanjutnya, setiap tweet direpresentasikan dalam bentuk Bag-of-Words (BoW), yaitu pasangan antara ID kata dan frekuensi kemunculannya dalam dokumen.

Tahap ketiga adalah pemodelan topik menggunakan Latent Dirichlet Allocation (LDA). Model LDA dilatih menggunakan corpus BoW dengan variasi jumlah topik antara 5 hingga 10 topik. Proses ini bertujuan untuk menemukan struktur topik laten yang paling optimal dari data Twitter. Setiap topik direpresentasikan oleh sekumpulan kata dengan probabilitas tertentu, sedangkan setiap dokumen direpresentasikan oleh distribusi topik.

Tahap keempat adalah evaluasi model, yang dilakukan menggunakan *coherence score* untuk menilai kualitas topik yang dihasilkan. Model dengan nilai coherence tertinggi dipilih sebagai model terbaik karena menunjukkan keterkaitan semantik antar kata yang lebih baik. Setelah model terbaik ditentukan, dilakukan pelatihan ulang untuk memperoleh topik final yang lebih stabil.

Tahap terakhir adalah analisis dan visualisasi hasil, meliputi penentuan topik dominan pada setiap tweet, interpretasi makna topik berdasarkan kata-kata penyusunnya, serta visualisasi distribusi topik dan wordcloud untuk membantu pemahaman hasil secara intuitif.

3.5 *PseudoCode* yang Digunakan

Langkah-langkah Pseudocode:

1. Memuat dataset Twitter dari file CSV.
2. Melakukan pengambilan sampel secara acak sebanyak 500 tweet.
3. Melakukan preprocessing teks pada setiap tweet, yang meliputi:
   a. Mengubah seluruh teks menjadi huruf kecil (*case folding*).
   b. Menghapus URL, mention, hashtag, angka, tanda baca, emoji, dan karakter khusus.
   c. Melakukan tokenisasi untuk memecah teks menjadi kata-kata.
   d. Menormalisasi kata tidak baku menggunakan kamus slang.
   e. Menghapus stopword yang bersifat umum dan tidak informatif.
   f. Melakukan stemming untuk memperoleh kata dasar.
4. Mengumpulkan seluruh token hasil preprocessing untuk membentuk *dictionary*.
5. Mengubah setiap tweet ke dalam representasi Bag-of-Words (BoW).
6. Menentukan beberapa variasi jumlah topik (misalnya 5 sampai 10 topik).
7. Untuk setiap jumlah topik yang diuji:
   a. Melatih model Latent Dirichlet Allocation (LDA).
   b. Menghitung nilai *coherence score* sebagai evaluasi kualitas topik.
8. Memilih jumlah topik dengan nilai *coherence score* tertinggi sebagai model terbaik.
9. Melatih ulang model LDA menggunakan jumlah topik terbaik tersebut.
10. Mengekstraksi kata-kata dominan dari setiap topik yang terbentuk.

11. Menentukan topik dominan pada setiap tweet berdasarkan probabilitas tertinggi.
12. Menyajikan hasil analisis dalam bentuk tabel dan visualisasi (distribusi topik dan *wordcloud*).

BAB IV
HASIL DAN ANALISIS

4.1 Hasil Model LDA beserta Skor Koherensi

Pada tahap ini dilakukan pemodelan topik menggunakan metode Latent Dirichlet Allocation (LDA) terhadap data Twitter yang telah melalui proses preprocessing meliputi case folding, filtering, stopword removal, stemming, tokenizing, dan normalisasi kata. Setelah proses pembersihan data, diperoleh 492 dokumen teks yang digunakan dalam pemodelan topik.

Model LDA dibangun menggunakan representasi Bag of Words (BoW) dengan jumlah 1.224 kata unik (dictionary). Untuk menentukan jumlah topik yang optimal, dilakukan pengujian model LDA dengan variasi jumlah topik mulai dari 5 hingga 10 topik. Evaluasi kualitas model dilakukan menggunakan Coherence Score, karena metrik ini mampu mengukur tingkat keterkaitan semantik antar kata dalam setiap topik. Hasil perhitungan skor koherensi untuk masing-masing jumlah topik ditunjukkan sebagai berikut:

Tabel 1 Skor Koherensi untuk masing-masing Jumlah Topik

Jumlah Topik	Coherence Score
5 topik	0,3440
6 topik	0,3322
7 topik	0,3386
8 topik	0,3146
9 topik	0,3131
10 topik	0,3299

Berdasarkan tabel tersebut, dapat dilihat bahwa model dengan 5 topik menghasilkan skor koherensi tertinggi, yaitu sebesar 0,3440. Hal ini menunjukkan bahwa model LDA dengan 5 topik memiliki tingkat keterkaitan kata dalam topik yang paling baik dibandingkan variasi jumlah topik lainnya. Oleh karena itu, jumlah topik optimal yang digunakan dalam penelitian ini adalah 5 topik.

Selanjutnya, model LDA dengan 5 topik dianalisis untuk melihat kata-kata dominan pada setiap topik. Hasil pemodelan menunjukkan bahwa setiap topik didominasi oleh kata-kata yang berkaitan dengan perasaan gelisah, cemas, takut, resah, dan kondisi emosional individu. Beberapa kata yang sering muncul pada berbagai topik antara lain gelisah, cemas, aku, rasa, takut, dan tidur. Hal ini mengindikasikan bahwa topik-topik yang terbentuk merepresentasikan berbagai bentuk ekspresi kecemasan dan kegelisahan pengguna Twitter.

Distribusi dokumen pada masing-masing topik juga menunjukkan bahwa seluruh topik memiliki jumlah data yang relatif signifikan, sehingga tidak terdapat topik yang bersifat minor atau tidak representatif. Dengan demikian, hasil pemodelan LDA dengan 5

topik dinilai mampu menggambarkan struktur topik utama dalam data secara optimal dan dapat digunakan untuk analisis lanjutan pada tahap berikutnya.

4.2 Topik yang Terbentuk

Berdasarkan hasil pemodelan topik menggunakan Latent Dirichlet Allocation (LDA), diperoleh 5 topik berdasarkan data yang digunakan sebagai berikut:

1. Konflik Batin dan *Overthinking*

   Topik 1 didominasi oleh kata *gelisah* (0,051), *aku* (0,030), dan *cemas* (0,017), diikuti oleh kata lain seperti *tapi*, *mau*, *rasa*, *kalau*, *sudah*, *terus*, dan *tidak*. Bobot pada setiap kata menunjukkan tingkat kontribusinya dalam membentuk topik, di mana semakin besar bobot maka semakin dominan peran kata tersebut. Dominasi kata *gelisah* dan *cemas* menunjukkan bahwa topik ini berkaitan dengan kondisi emosional individu yang ditandai oleh perasaan tidak tenang dan kecemasan yang bersifat personal, sebagaimana tercermin dari penggunaan kata *aku*.

   Selain itu, kemunculan kata-kata seperti *tapi*, *kalau*, *tidak*, dan *terus* mengindikasikan adanya pola pikir berulang dan kontradiktif yang sering dikaitkan dengan overthinking, di mana individu terus-menerus memikirkan berbagai kemungkinan dan perasaan secara berlebihan. Kata *rasa* dan *mau* juga mencerminkan konflik antara perasaan dan keinginan pribadi, sedangkan kata *sudah* dan *terus* menunjukkan bahwa kondisi tersebut berlangsung secara berkelanjutan.

2. Ketakutan terhadap Situasi Tertentu

   Topik 2 ditandai oleh kata-kata dengan bobot tertinggi seperti *cemas* (0,045), *aku* (0,024), *rasa* (0,018), dan *tidak* (0,016), yang diikuti oleh kata *gelisah* (0,014), *baca* (0,008), *sampai* (0,007), *kalau* (0,007), dan *tulis* (0,007). Bobot pada setiap kata menunjukkan tingkat kontribusi kata dalam membentuk topik, sehingga kata dengan bobot lebih besar memiliki peran yang lebih dominan. Dominasi kata *cemas* dan *gelisah* kembali menegaskan bahwa topik ini berkaitan dengan kondisi emosional individu yang diliputi kecemasan, dengan sudut pandang yang bersifat personal sebagaimana tercermin dari penggunaan kata *aku*.

   Selain itu, kemunculan kata-kata seperti *baca* dan *tulis* menunjukkan bahwa kecemasan yang dialami individu berkaitan dengan aktivitas tertentu, khususnya aktivitas kognitif seperti membaca atau menulis. Kata *tidak*, *kalau*, dan *sampai* mengindikasikan adanya hambatan atau kesulitan dalam menyelesaikan aktivitas tersebut akibat perasaan cemas yang muncul. Hal ini menunjukkan bahwa Topik 2 merepresentasikan kecemasan yang memengaruhi kemampuan fokus dan aktivitas sehari-hari, terutama dalam konteks membaca dan menulis.

3. Harapan untuk Tenang

   Topik 3 didominasi oleh kata-kata dengan bobot tertinggi seperti *gelisah* (0,066), *cemas* (0,025), dan *resah* (0,020), yang diikuti oleh kata *hati* (0,016), *hari* (0,016), *harap* (0,015), *sendiri* (0,012), *orang* (0,011), *kenapa* (0,010), dan *tenang* (0,008). Bobot tersebut menunjukkan bahwa kata *gelisah*, *cemas*, dan *resah* memiliki kontribusi terbesar dalam membentuk karakteristik topik. Dominasi kata-kata ini

mengindikasikan kondisi emosional individu yang tidak stabil dan dipenuhi perasaan gelisah serta kecemasan yang berkelanjutan.

Selain itu, kemunculan kata *harap* dan *tenang* menunjukkan adanya keinginan atau aspirasi individu untuk mencapai ketenangan batin di tengah perasaan cemas yang dialami. Kata *sendiri* dan *orang* mencerminkan aspek sosial, di mana individu mungkin merasakan kegelisahan secara personal atau dalam hubungannya dengan orang lain. Sementara itu, kata *kenapa* mengindikasikan adanya proses refleksi dan pencarian makna terhadap kondisi yang dialami.

4. Ketakutan atau Kecemasan Mendadak

Topik 4 ditandai oleh kata-kata dengan bobot tertinggi seperti *cemas* (0,033), *gelisah* (0,027), dan *takut* (0,026), yang diikuti oleh kata *tidak* (0,019), *tiba* (0,018), *aku* (0,013), *pikir* (0,009), *pasti* (0,008), dan *dadak* (0,008). Bobot kata-kata tersebut menunjukkan bahwa emosi kecemasan, kegelisahan, dan ketakutan memiliki peran dominan dalam membentuk topik ini. Kehadiran kata *tiba* dan *dadak* mengindikasikan bahwa perasaan tersebut muncul secara mendadak tanpa pemicu yang jelas.

Selain itu, kata *pikir* dan *pasti* menunjukkan adanya proses kognitif yang terjadi setelah munculnya kecemasan secara tiba-tiba, di mana individu mulai memikirkan berbagai kemungkinan atau dampak dari perasaan tersebut. Penggunaan kata *aku* kembali menegaskan bahwa pengalaman yang digambarkan bersifat personal dan subjektif.

5. Gangguan Tidur Akibat Kecemasan

Topik 5 didominasi oleh kata-kata dengan bobot tertinggi seperti *gelisah* (0,062), *cemas* (0,028), *banget* (0,020), dan *aku* (0,019), yang diikuti oleh kata *tidur* (0,018), *rasa* (0,014), *kenapa* (0,013), *hari* (0,011), *seperti* (0,011), dan *sudah* (0,011). Bobot tersebut menunjukkan bahwa perasaan gelisah dan cemas memiliki kontribusi paling besar dalam membentuk topik ini, dengan intensitas emosi yang diperkuat oleh kata *banget*. Kehadiran kata *tidur* menjadi ciri utama yang membedakan topik ini dari topik lainnya.

Selain itu, kemunculan kata *hari* dan *sudah* mengindikasikan bahwa kondisi tersebut terjadi secara berulang dan berlangsung dalam periode waktu tertentu, bukan hanya sesaat. Kata *kenapa* mencerminkan adanya kebingungan atau pencarian alasan atas kondisi yang dialami, sementara kata *aku* kembali menegaskan bahwa pengalaman yang disampaikan bersifat personal.

4.3 Perbandingan Hasil dengan Penelitian Sejenis

Penelitian terkait *topic modeling* telah dilakukan oleh Bagas Raditya Nur Listyawan, Nanang Yudi Setiawan, dan Mochamad Chandra Saputra pada tahun 2017 melalui artikel berjudul "Topic Modelling pada Aktivitas Pengembangan Perangkat Lunak Menggunakan BERTopic". Penelitian tersebut bertujuan untuk mengidentifikasi topik-topik utama pada aktivitas pengembangan perangkat lunak dengan menggunakan pendekatan BERTopic

yang mengombinasikan representasi embedding berbasis transformer dengan algoritma clustering.

Perbedaan dengan *Topic Modeling* yang dilakukan pada proyek ini adalah digunakannya Latent Dirichlet Allocation (LDA) sebagai metode *Topic Modeling*. LDA merupakan model yang mengasumsikan bahwa setiap dokumen merupakan kombinasi dari beberapa topik dan setiap topik terdiri atas distribusi kata tertentu. Sementara BERTopic memanfaatkan embedding sehingga mampu menangkap makna yang lebih kompleks. LDA dipilih dalam proyek ini karena lebih mudah diinterpretasikan, ringan secara komputasi, dan sesuai untuk analisis data teks ukuran menengah. Untuk hasilnya, penelitian Bagas dkk menghasilkan topik-topik yang berkaitan tentang pengembangan perangkat lunak seperti pengelolaan kode, perbaikan bug, dan kolaborasi tim. Sementara pada proyek kami membawakan tema emosional seperti kecemasan dan kegelisahan. Perbedaan ini menunjukkan bahwa konteks data yang digunakan sangat memengaruhi karakteristik topik yang dihasilkan.

Dengan demikian, meskipun proyek ini dan penelitian yang dilakukan Bagas dkk sama-sama menggunakan pendekatan *Topic Modeling*, perbedaan metode, jenis data, dan tujuan analisis menghasilkan karakteristik topik yang berbeda. Hal ini menunjukkan bahwa pemilihan metode *Topic Modeling* perlu disesuaikan dengan konteks penelitian dan karakteristik data yang dianalisis.

BAB V
PENTUTUP

5.1 Ringkasan Temuan Utama Proyek.

Proyek ini telah berhasil menerapkan metode Topic Modeling dengan Latent Dirichlet Allocation (LDA) untuk menganalisis percakapan tentang kecemasan dan kegelisahan dalam media sosial berbahasa Indonesia. Berikut adalah temuan utama yang dapat disimpulkan:

1. Optimalisasi Jumlah Topik

   Berdasarkan evaluasi koherensi (coherence score), model dengan 5 topik menghasilkan skor tertinggi (0,3440), yang menunjukkan bahwa struktur topik dalam data paling koheren dan mudah diinterpretasikan pada jumlah tersebut.
2. Identifikasi Topik Utama

   Lima topik utama yang berhasil diekstraksi mencerminkan berbagai dimensi emosional dan kognitif dari kecemasan, yaitu:
   - Topik 1: Konflik batin dan overthinking
   - Topik 2: Ketakutan terhadap situasi tertentu (misalnya membaca/menulis)
   - Topik 3: Harapan untuk mencapai ketenangan
   - Topik 4: Kecemasan mendadak tanpa pemicu jelas
   - Topik 5: Gangguan tidur akibat kecemasan
3. Karakteristik Kata Kunci Emosional

   Kata-kata seperti “gelisah”, “cemas”, “aku”, “takut”, “tidur”, dan “rasa” mendominasi berbagai topik, yang mengindikasikan bahwa percakapan tentang kecemasan di media sosial sangat personal dan sarat dengan ekspresi emosi subjektif.
4. Distribusi Topik yang Seimbang

   Analisis distribusi dokumen menunjukkan bahwa seluruh topik memiliki jumlah data yang signifikan, dengan topik “Konflik Batin” dan “Gangguan Tidur” sebagai yang paling dominan. Hal ini mencerminkan variasi pengalaman kecemasan yang dialami pengguna.
5. Validitas Metodologis:

   Proses preprocessing yang meliputi normalisasi slang, penghapusan stopword, dan stemming terbukti efektif dalam meningkatkan kualitas input untuk LDA. Penggunaan kamus kustom juga membantu dalam menangani karakteristik bahasa informal media sosial.
6. Relevansi Sosial dan Kesehatan Mental

   Temuan ini memberikan gambaran bahwa media sosial menjadi ruang penting bagi individu untuk mengekspresikan pergumulan emosional, sekaligus mencerminkan kebutuhan akan perhatian lebih terhadap isu kesehatan mental di Indonesia.

5.2 Saran

Berdasarkan temuan dan keterbatasan yang ada dalam proyek ini, berikut adalah beberapa saran untuk pengembangan penelitian sejenis di masa depan:

1. Perluasan Data dan Sumber

   Disarankan untuk menggunakan dataset yang lebih besar dan berasal dari berbagai platform media sosial (Instagram, TikTok, forum kesehatan mental) untuk mendapatkan gambaran yang lebih komprehensif tentang percakapan kecemasan.
2. Penggunaan Model yang Lebih Kompleks

   Eksperimen dengan model topic modeling lain seperti BERTopic, NMF, atau LDA dengan embedding kontekstual dapat dipertimbangkan untuk menangkap nuansa makna yang lebih dalam dan hubungan semantik yang lebih kompleks.
3. Integrasi dengan Analisis Sentimen atau Emosi

   Topik yang dihasilkan dapat diperkaya dengan analisis sentimen atau klasifikasi emosi untuk memahami polarity dan intensitas emosi dalam setiap topik, sehingga interpretasi menjadi lebih kaya.
4. Validasi Kualitatif dengan Ahli

   Melibatkan psikolog atau konselor kesehatan mental dalam proses interpretasi topik dapat meningkatkan validitas temuan dan relevansi klinis dari hasil penelitian.
5. Pengembangan Sistem Deteksi Dini

   Hasil penelitian ini dapat dikembangkan menjadi prototipe sistem pemantauan (monitoring tool) untuk mendeteksi percakapan berisiko tinggi terkait kecemasan, sehingga dapat dirujuk ke layanan dukungan kesehatan mental.
6. Peningkatan Kamus dan Stopword Kustom

   Kamus normalisasi dan stopword sebaiknya terus diperbarui seiring perkembangan bahasa gaul dan pola komunikasi di media sosial Indonesia.
7. Eksplorasi Topik Spesifik dan Intervensi

   Penelitian lanjutan dapat fokus pada topik spesifik seperti kecemasan akademik, pekerjaan, atau sosial, serta mengeksplorasi bentuk intervensi digital yang sesuai berdasarkan temuan topik.
8. Publikasi dan Diseminasi Hasil

   Hasil penelitian ini dapat dipublikasikan dalam bentuk artikel ilmiah atau dibagikan kepada lembaga kesehatan mental untuk mendukung program edukasi dan kesadaran masyarakat.

DAFTAR PUSTAKA

Listyawan, B. R. N., Setiawan, N. Y., & Saputra, M. C. (2017). Topic Modelling Pada Aktivitas Pengembangan Perangkat Lunak Menggunakan BERTopic. *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer* 1(1): 1-11.

Setiawan, G. H., Pranata, M. D. A., Arimbawa, I. B. A., Giri, I. W. P., & Dayani, N. P. L. C. (2025). Topic Clustering of Student Complaints Based on Semantic Meaning Using the IndoBERT and K-Means Models. *Journal of Applied Informatics and Computing (JAIC)*, 9(4): 1715–1721. https://jurnal.polibatam.ac.id/index.php/JAIC/article/view/10080.

LAMPIRAN

Lampiran 1. Tautan Kode Program (Google Colab)

Tautan:https://colab.research.google.com/drive/195Rynqjtn7poJKJHyEpPe06PlLJ5h7BN?usp=sharing

Keterangan: Berisi seluruh kode preprocessing, pelatihan LDA, evaluasi koherensi, serta visualisasi (distribusi topik dan wordcloud).

Lampiran 2. Tautan Data yang Digunakan

A. Sumber data (dataset awal dari Kaggle)

https://www.kaggle.com/datasets/stevenhans/depression-and-anxiety-in-twitter-id

Keterangan: Dataset mentah berisi unggahan Twitter/X berbahasa Indonesia terkait depresi dan kecemasan.

B. Dataset hasil sampling (500 unggahan)

https://drive.google.com/file/d/1GC0v9tMukHPBr9XKBu2zDzZBFD1vyVUB/view?usp=sharing

Keterangan: Data yang telah dipilih menjadi 500 unggahan untuk dianalisis pada proyek ini.

Lampiran 3. Gambar Wordcloud

Gambar 1. Wordcloud Data Keseluruhan

Lampiran 4. Kata terbanyak tiap topik

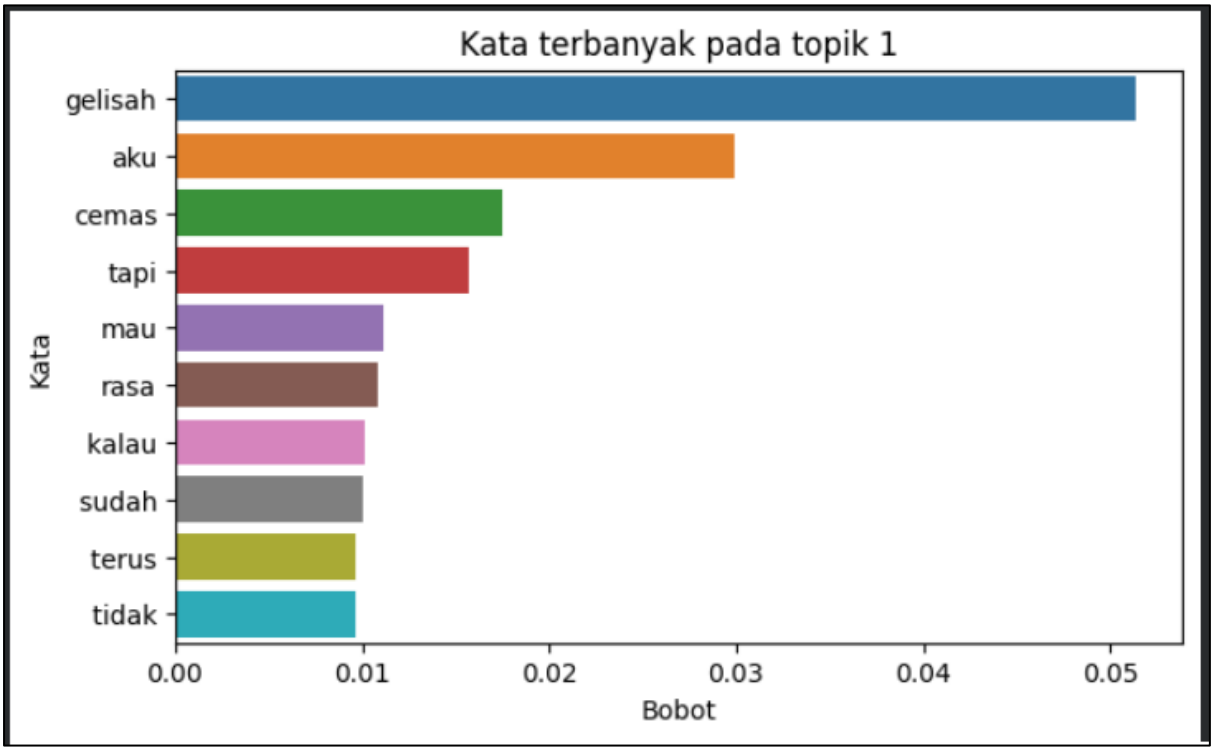

Gambar 2. Kata Terbanyak pada Topik 1

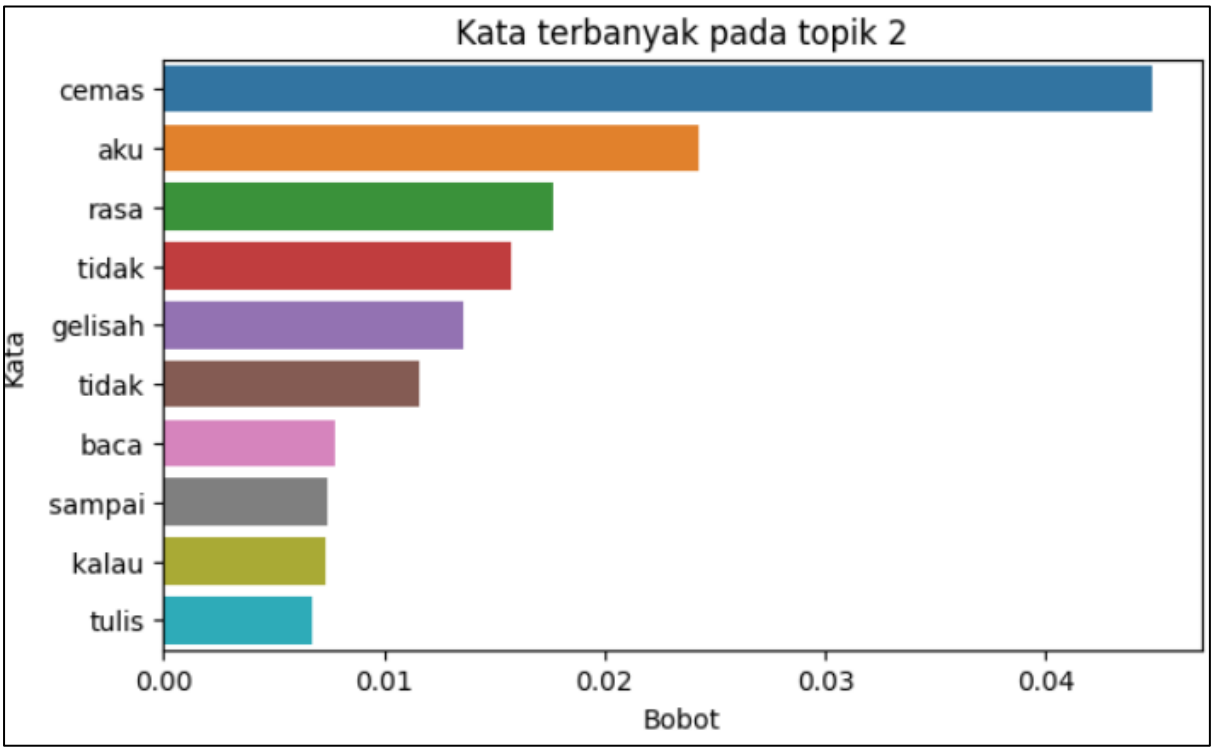

Gambar 3. Kata Terbanyak pada Topik 2

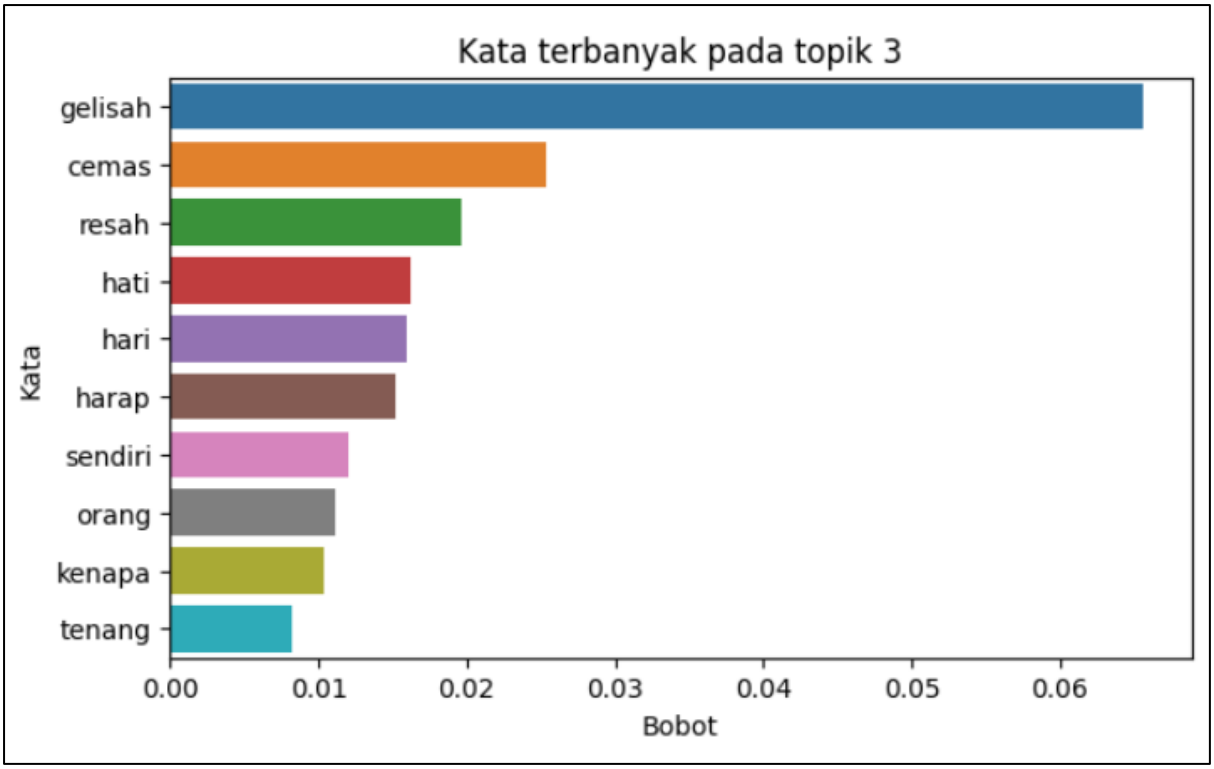

Gambar 4. Kata Terbanyak pada Topik 3

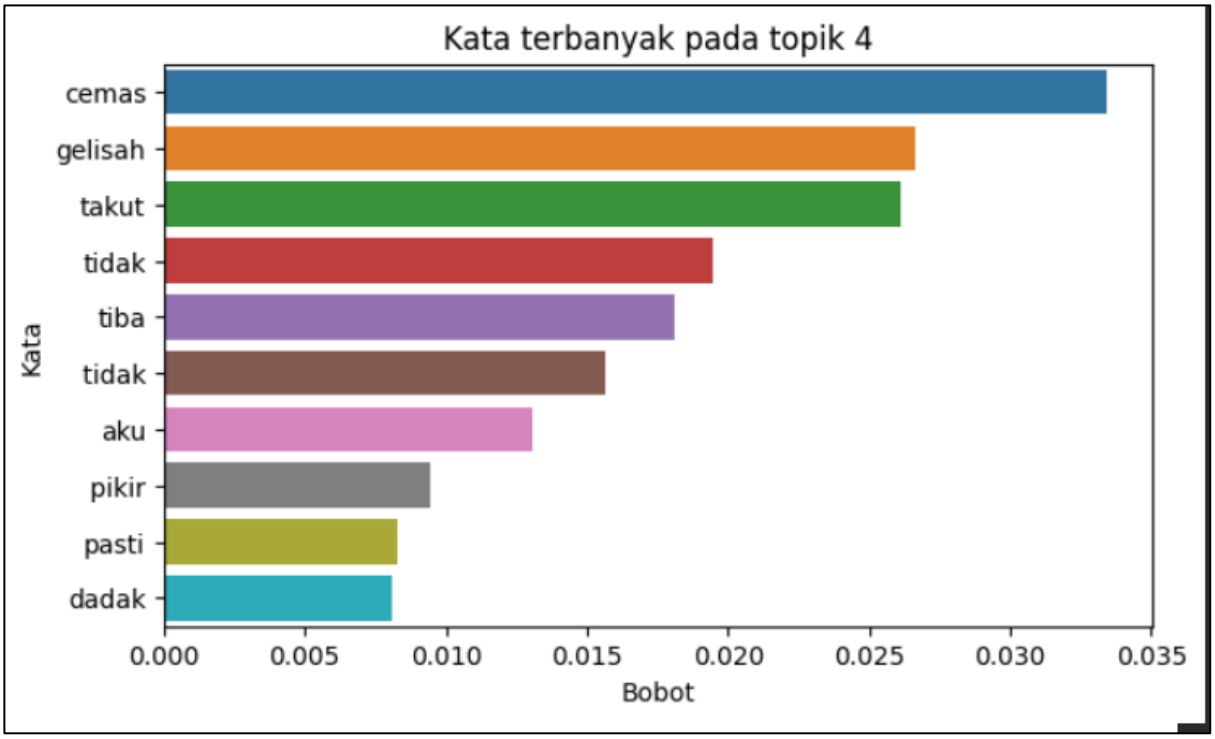

Gambar 5. Kata Terbanyak pada Topik 4

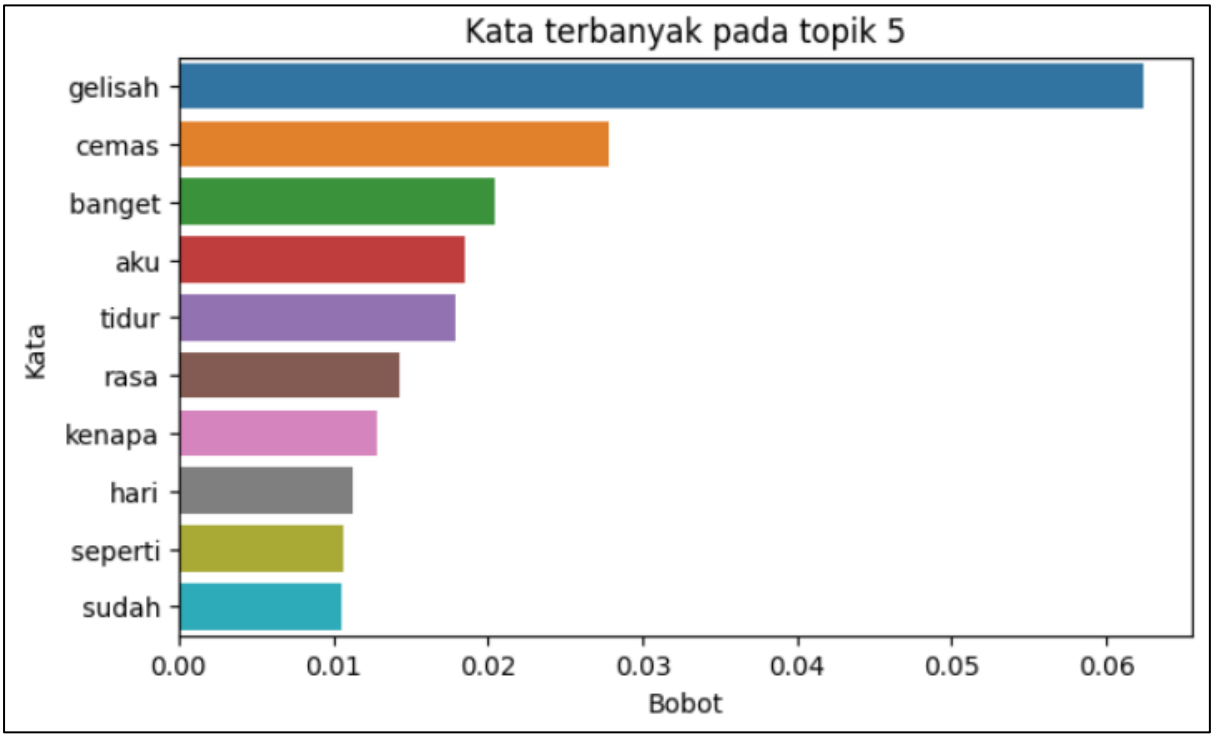

Gambar 6. Kata Terbanyak pada Topik 5